

UNIVERSIDAD SANTO TOMÁS

Maestría en Ciencia de Datos

Asignatura: **Inteligencia Artificial Explicativa e Inferencia Causal**

Explicar no es entender: IA explicativa y sus límites causales

Estudio de caso: predicción de sitios de anidación de la tórtola senegalesa (*Spilopelia senegalensis*) en Karaj, Irán

Presentado por: Jaidy Viviana Narváez

Docente: Mario José Pacheco López

Tipo de actividad: Informe técnico (Taller práctico – Guía de actividades 1)

Bogotá, Colombia
2026

1. Introducción

La inteligencia artificial explicable (XAI) busca facilitar la comprensión de las decisiones tomadas por modelos de aprendizaje automático, especialmente cuando estos presentan un funcionamiento complejo o difícil de interpretar directamente. No basta con conocer qué tan bien predice un modelo; también es importante identificar qué características utiliza para predecir y reconocer los límites de dichas explicaciones, en particular su distancia frente a una explicación causal.

El presente informe desarrolla un estudio de caso sobre 96 sitios urbanos de anidación de la tórtola senegalesa (*Spilopelia senegalensis*) en Karaj, Irán (32 con presencia de nido y 64 sin presencia; Banisaffar y Alizadeh Shabani, 2024). El objetivo es entrenar un modelo de caja negra –Random Forest– capaz de predecir la presencia de nidos a partir de características físicas y ambientales del sitio, explicar su comportamiento mediante SHAP y LIME (globales y locales), analizar la dependencia de una variable clave mediante PDP, ICE y ALE, diagnosticar posibles variables *proxy* mediante SHAP intervencional y, finalmente, formular una pregunta causal que las técnicas de explicabilidad no permiten responder por sí solas. Este último punto constituye el eje central del informe: diferenciar explícitamente entre lo que el modelo *utiliza* para predecir y lo que realmente *causa* la selección de un sitio de anidación.

2. Datos y modelo

2.1 Descripción de los datos

El conjunto contiene 96 sitios urbanos, codificados como P_A (1 = presencia, 0 = ausencia de nido). Las diez variables explicativas describen aspectos físicos y ambientales del sitio: HEIGHT (altura sobre el suelo), CEILING (distancia vertical al techo), H_CEILING (distancia horizontal al borde del techo), TREE_DIST, BUILD_DIST, GREEN_DIST y NEST_DIST (distancias al árbol, al edificio opuesto, a la zona verde y al nido más cercano, respectivamente), además de tres variables categóricas: CONCEAL (nivel de ocultamiento), B_ASPECT (orientación) y B_STRUCT (tipo de soporte). Estas últimas se transformaron mediante *One-Hot Encoding* antes del entrenamiento, y los datos se dividieron en entrenamiento (67 sitios) y prueba (29 sitios) mediante una partición estratificada 70/30 que conserva la proporción 32/64 entre clases.

Variables como CONCEAL y B_STRUCT describen una condición funcional directa del sitio (protección frente a depredadores o intemperie), por lo que resultan razonables como posibles causas de la elección. En cambio, TREE_DIST, GREEN_DIST o BUILD_DIST podrían estar acompañando a otras condiciones del entorno que no se midieron directamente, como la cantidad de vegetación urbana del sector. Por eso conviene explicar el modelo y no quedarse solo con su capacidad predictiva: un modelo de caja negra puede predecir bien apoyándose en variables que simplemente acompañan al fenómeno, sin que eso signifique que son la causa real de la selección del sitio.

2.2 Modelo predictivo

Se entrenó un **Random Forest** (300 árboles, `min_samples_leaf=2`) dentro de un Pipeline que integra el preprocesamiento categórico y el clasificador, por su capacidad de representar relaciones no lineales entre las variables. La Tabla 1 resume el desempeño en el conjunto de prueba.

Tabla 1: Desempeño del modelo en el conjunto de prueba (29 sitios: 19 sin nido, 10 con nido)


Métrica	Accuracy	F1 (clase presencia)	ROC AUC
Valor	0.793	0.667	0.784
Matriz de confusión (filas = real, columnas = predicho)			
	Pred. Ausencia	Pred. Presencia	
Real Ausencia (19)	17	2	
Real Presencia (10)	4	6	

Con solo 29 sitios en prueba, cada observación pesa considerablemente en las métricas: un solo error de clasificación mueve el *accuracy* o el F1 varios puntos porcentuales. El modelo alcanza una exactitud razonable (0.793) y un ROC AUC de 0.784, lo que indica una capacidad de discriminación moderada-buena; sin embargo, el F1 de la clase minoritaria (presencia, 0.667) es menor que el *accuracy* global, reflejando que la clase con nido –representada por solo 32 de 96 sitios– es más difícil de identificar. Estos resultados deben tomarse como una estimación con incertidumbre considerable dado el tamaño muestral reducido y el desbalance de clases (32/64), y no como una medida definitiva de desempeño.

3. Explicación del modelo

3.1 Explicación global mediante SHAP

Se calcularon los valores SHAP sobre el conjunto de prueba usando TreeExplainer, y se resumió la importancia global de cada variable mediante el promedio de sus valores SHAP en valor absoluto (Figura 1). CONCEAL (0.096) resultó la variable más relevante para el modelo, seguida por HEIGHT (0.056) y CEILING (0.041). Con relevancia intermedia aparecen BUILD_DIST, B_ASPECT, B_STRUCT, NEST_DIST y H_CEILING, mientras que GREEN_DIST (0.010) mostró la menor importancia relativa. Es importante aclarar que estos resultados describen qué variables usa más el modelo para predecir, y no deben leerse como si esas variables causaran la presencia del nido.

**Figura 1:** Importancia global mediante SHAP (media de |SHAP| sobre el conjunto de prueba).

3.2 Explicación local: SHAP y LIME

Para ilustrar el comportamiento local del modelo se seleccionó, dentro del conjunto de prueba, un sitio con presencia observada de nido, clasificado correctamente con probabilidad estimada de **0.760** frente a un valor base de **0.337**. Según SHAP (Figura 2), las mayores contribuciones positivas provienen de CONCEAL (+0.139), CEILING (+0.089) y HEIGHT (+0.071), seguidas por H_CEILING y BUILD_DIST; B_ASPECT presentó una pequeña contribución negativa (−0.014).




Figura 2: Explicación local con SHAP para el sitio seleccionado del conjunto de prueba.

La explicación con LIME sobre el mismo sitio arrojó una predicción local de 0.465 (con una fidelidad $R^2 = 0.641$, es decir, el modelo lineal local explica razonablemente bien la predicción, aunque no de forma perfecta), con CONCEAL=A (+0.187) y B_STRUCT=A (+0.039) como principales impulsores positivos, y NEST_DIST y CEILING con contribuciones negativas menores. Ambas explicaciones coinciden en que CONCEAL es, por amplio margen, el factor que más aumenta la probabilidad de presencia, lo que refuerza la evidencia de que esta variable es relevante para las predicciones del modelo; difieren en magnitudes y en variables secundarias, lo cual tiene sentido porque cada método aproxima la predicción de una forma distinta. En cualquier caso, tanto SHAP como LIME muestran *cómo llegó el modelo a esa predicción*, no por qué la tórtola eligió ese sitio: no permiten afirmar que modificar una característica cambiaría realmente la probabilidad de anidación.

3.3 SHAP frente a la importancia por permutación

La importancia por permutación (que mide cuánto empeora el *accuracy* del modelo si se desordena una variable) ubicó a HEIGHT (0.113), B_ASPECT (0.070) y CONCEAL (0.055) como las más relevantes, en un orden un poco distinto al de SHAP global. Esto ocurre porque cada método mide algo diferente: la permutación se fija en cuánto se afecta el desempeño del modelo, mientras que SHAP reparte la predicción de cada sitio entre las variables. Cuando dos variables están relacionadas, el modelo puede “compensar” la pérdida de una usando la otra, lo que genera pequeños cambios en el orden sin que esto sea una contradicción entre los métodos. Lo importante es que CONCEAL y HEIGHT aparecen entre las más relevantes en ambos análisis, lo que refuerza que el modelo realmente se apoya en ellas para predecir, aunque esto siga siendo información predictiva y no causal.

3.4 PDP, ICE y ALE para HEIGHT

Se analizó HEIGHT, la variable numérica con mayor relevancia. El PDP (Figura 3, línea gruesa) muestra que la probabilidad promedio de presencia aumenta con HEIGHT hasta un rango intermedio-alto y luego se estabiliza; las curvas ICE individuales muestran que esta relación no es igual para todos los sitios, algunos incluso presentan una tendencia distinta a la del promedio, lo que sugiere que HEIGHT interactúa con otras variables (por ejemplo CONCEAL o B_STRUCT). El gráfico ALE (Figura 3) confirma una tendencia creciente parecida, aunque con magnitudes distintas, lo cual es razonable porque HEIGHT tiene cierta relación con NEST_DIST ($r \approx 0.32$). En conjunto, el modelo asocia alturas mayores con una mayor probabilidad de anidación, sobre todo en sitios que ya tienen buen ocultamiento y buen soporte; esto describe *cómo predice* el modelo, no necesariamente *por qué* las tórtolas eligen esos sitios.




Figura 3: Izquierda: PDP (línea gruesa) e ICE (líneas individuales) para HEIGHT. Derecha: gráfico ALE para HEIGHT.

4. Diagnóstico de posibles variables proxy

Los valores SHAP de este informe se calcularon usando la opción de atribución *intervencional* de la librería, que busca reducir la influencia que puede tener la relación entre una variable y las demás al calcular sus contribuciones. Aun así, esto no elimina el hecho de que dos variables relacionadas puedan compartir información real sobre el sitio. El análisis de correlaciones (Tabla 2) permitió identificar que algunas variables pueden estar relacionadas entre sí y representar información parecida sobre el entorno del sitio.

Tabla 2: Correlaciones relevantes entre variables numéricas

Par de variables	Correlación
HEIGHT – NEST_DIST	0.322
HEIGHT – CEILING	−0.213
TREE_DIST – GREEN_DIST	0.075

HEIGHT presenta una relación moderada con NEST_DIST y con CEILING, lo que indica que la altura del sitio no es del todo independiente de otras características del edificio. Por eso, parte de la importancia que el modelo le da a HEIGHT podría reflejar en realidad un patrón compartido

con esas otras variables, y no un efecto exclusivo de la altura en sí misma. De forma parecida, `B_STRUCT` y `CONCEAL` suelen ir de la mano, ya que ciertos tipos de soporte (como los balcones) ofrecen naturalmente más ocultamiento que otros (como los avisos), por lo que resulta difícil separar completamente el efecto de una y otra. `TREE_DIST` y `GREEN_DIST`, aunque en esta muestra están poco correlacionadas (0.075), también podrían estar asociadas a un factor común no medido directamente, como la cantidad de vegetación urbana del sector.

Esto es importante porque una variable puede aparecer como relevante para el modelo no necesariamente porque tenga un efecto directo sobre la presencia de nidos, sino porque está relacionada con otras condiciones del sitio que sí podrían ser más determinantes. Por esta razón, los resultados de SHAP y LIME deben interpretarse como una explicación del comportamiento predictivo del modelo, y no como evidencia de que esas variables causan la selección del sitio. Para afirmar que una característica realmente produce un cambio en la anidación sería necesario contar con un diseño de estudio que permita evaluar dicho efecto de manera causal, como se discute en la siguiente sección.

5. Pregunta causal y límites de la explicación

Las técnicas utilizadas permiten responder preguntas sobre el comportamiento del modelo (“¿qué características usa para predecir?”, “¿por qué predijo esto para este sitio?”), pero estas preguntas son distintas de una pregunta causal. Se formula aquí la siguiente:

¿Qué ocurriría con la probabilidad de anidación de un sitio si se modificara su nivel de ocultamiento (`CONCEAL`), manteniendo comparables las demás condiciones del sitio (altura, distancias, orientación, soporte)?

Para responder esta pregunta no bastaría con observar que los sitios con mayor ocultamiento tienen, en los datos, una mayor probabilidad de presentar nidos; eso es justamente lo que ya muestran SHAP, LIME, PDP, ICE y ALE, y sigue siendo una asociación observada, no una intervención real. Sería necesario, en cambio, estudiar qué pasaría si el ocultamiento de un sitio se modificara de forma activa, manteniendo en lo posible las demás condiciones iguales, algo que ninguna de estas técnicas simula por sí sola.

Una forma de estudiar esta pregunta sería mediante un experimento o cuasi-experimento, en el que se modifique el ocultamiento de un grupo de sitios comparables y se observe si cambia la tasa de anidación posterior. Otra alternativa sería construir un modelo causal (por ejemplo, un diagrama que represente cómo se relacionan `CONCEAL`, `B_STRUCT`, `HEIGHT` y las demás variables) que permita identificar qué otros factores deberían tenerse en cuenta para no confundir el efecto del ocultamiento con el de otra variable relacionada.

Además, el estudio presenta limitaciones importantes que deben reconocerse: los 96 sitios no fueron asignados de forma aleatoria a distintos niveles de ocultamiento, por lo que podrían diferir entre sí en otras condiciones no medidas; el tamaño de muestra es reducido (96 observaciones, 32 con nido) y las clases están desbalanceadas (32/64), lo que aumenta la incertidumbre de cualquier estimación; y, como se vio en la sección anterior, existen variables del entorno relacionadas entre sí, por lo que cualquier intento de estimar un efecto causal debería tener mucho cuidado al decidir

qué variables ajustar y cuáles no, pues un ajuste mal hecho podría distorsionar el resultado en lugar de corregirlo.

6. Conclusiones

El Random Forest desarrollado tiene una capacidad predictiva moderada-buena ($accuracy \approx 0.79$, $ROC\ AUC \approx 0.78$) para distinguir sitios con y sin nido, aunque le cuesta más identificar la clase minoritaria (presencia, $F1 \approx 0.67$); esto debe interpretarse con cautela dado el tamaño reducido de la muestra y el desbalance 32/64. CONCEAL (ocultamiento) es, de forma consistente entre SHAP global, SHAP local, LIME y –en menor medida– permutación, la variable que más usa el modelo para predecir, seguida por HEIGHT y las distancias al techo (CEILING, H_CEILING). El análisis de PDP, ICE y ALE confirma que a mayor HEIGHT el modelo predice una mayor probabilidad de presencia, aunque este patrón no es igual en todos los sitios, lo que sugiere que interactúa con otras variables.

El diagnóstico de proxies mostró que varias variables estructurales (HEIGHT, CEILING, NEST_DIST, B_STRUCT, CONCEAL) están relacionadas entre sí, por lo que su importancia individual debe interpretarse con cuidado, y en particular no debe tomarse como evidencia de causalidad. Se formuló explícitamente una pregunta causal –el efecto de modificar CONCEAL– que las explicaciones de este estudio **no** responden, y se señaló qué se necesitaría para abordarla en el futuro (un experimento o un modelo causal explícito).

En conclusión, **explicar un modelo no equivale a demostrar una relación causal**. SHAP, LIME, PDP, ICE y ALE permiten comprender mejor cómo llega el Random Forest a sus predicciones, pero para saber qué características producen realmente un cambio en la probabilidad de anidación haría falta un diseño de estudio distinto, capaz de evaluar intervenciones y de controlar los posibles factores de confusión. Esa distinción constituye el principal aprendizaje de este trabajo y conecta directamente con los contenidos de inferencia causal de la siguiente sección del curso.

Referencias

- Banisaffar, M., y Alizadeh Shabani, A. (2024). *Factors influencing nest site selection of the Laughing Dove (Spilopelia senegalensis) in an urban area in Karaj, Iran* [Conjunto de datos]. Dryad.
- Molnar, C. (2022). *Interpretable machine learning: A guide for making black box models explainable* (2.^a ed.). <https://christophm.github.io/interpretable-ml-book/>
- SHAP. (s.f.). *SHAP documentation*. <https://shap.readthedocs.io/>
- Zainea Maya, C. I. (2026). *Explicar no es entender: IA explicativa y sus límites causales*. Universidad Santo Tomás.